

Echtzeit-Datenverarbeitung mit Apache Kafka und Apache Spark

Beispiele aus der Praxis

Netflix generiert in Echtzeit neue Empfehlungen für TV-Shows



PayPal überprüft in Echtzeit Transaktionen auf möglichen Betrug



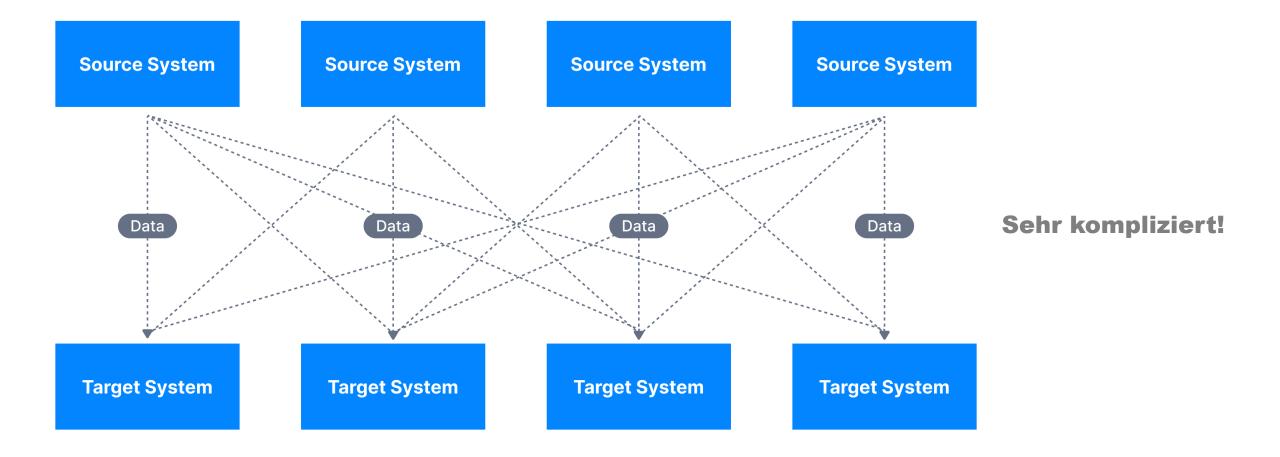
Agenda

- 1. Grundlagen von Apache Kafka
- Kleine Pause
- 2. Apache Kafka: Hands-On
- Pause
- 3. Grundlagen von Apache Spark
- 4. Einführung in Databricks
- Kleine Pause
- 5. Apache Spark mit Databricks: Hands-On

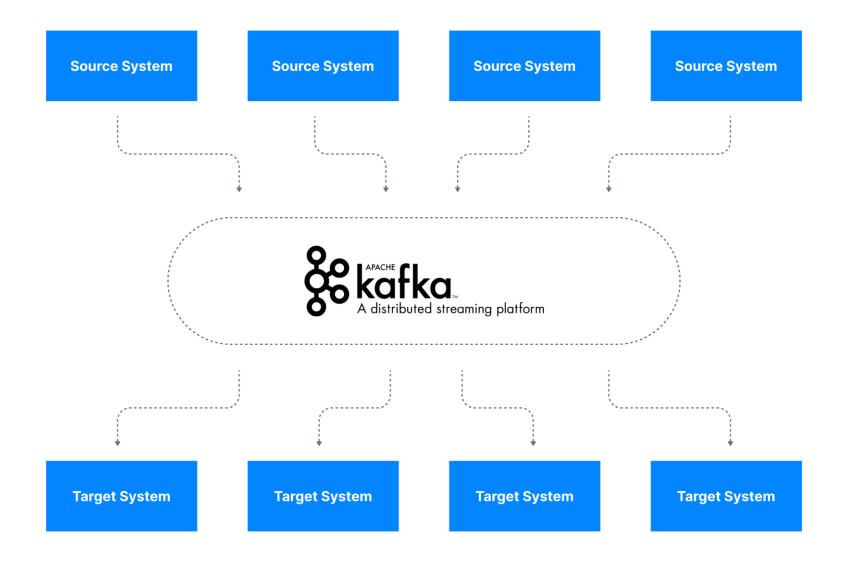


Apache Kafka

Ausgangssituation in Unternehmen



Apache Kafka zur Rettung



Argumente für Apache Kafka





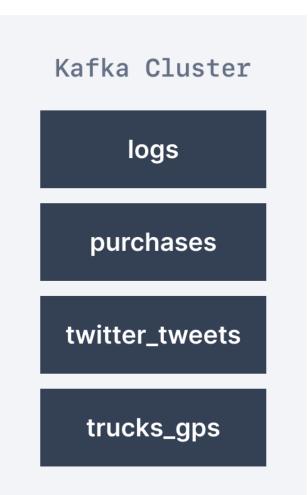
Skalierbarkeit



Topics

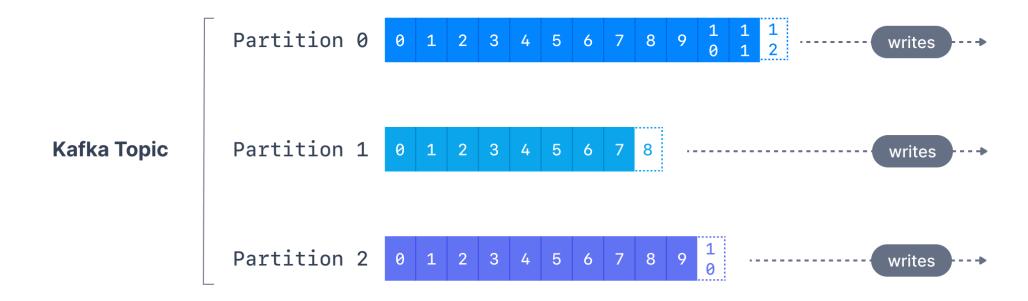
Topic: eine Sammlung von Nachrichten mit einem eindeutigen Namen

- Eine neue Nachricht wird immer an das Ende des Topics geschrieben (append-only)
- In das Topic geschriebene Nachrichten sind unveränderbar (immutable)
- Keine Vorgabe, welches Format der Inhalt einer Nachricht haben muss
- Producer erzeugen und Consumer konsumieren Nachrichten



Partitionen und Offsets

- Ein Topic wird in mehrere Partitionen aufgeteilt
- Jede Nachricht innerhalb einer Partition erhält eine inkrementelle ID (Offset)
- Die korrekte Reihenfolge der Nachrichten ist nur innerhalb einer Partition gewährleistet



Broker

Broker: Ein einzelner Server in einem Kafka-Cluster

- Jeder Broker enthält bestimmte Partitionen eines Topics
- Broker dienen der horizontalen Skalierung bei h\u00f6herer Rechenlast

Topic-A
Partition 0

Topic-B
Partition 1

Topic-A
Partition 2

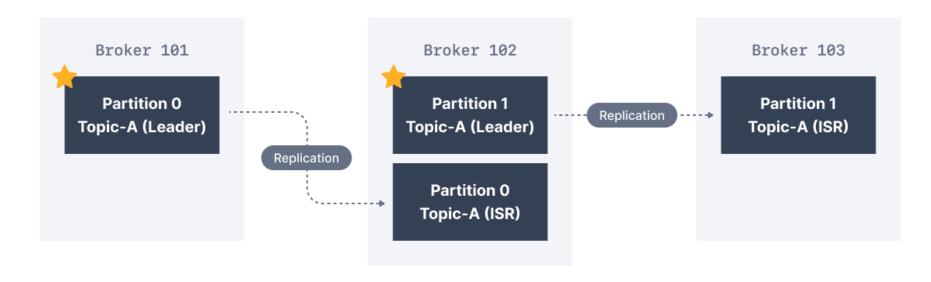
Topic-B
Partition 0

Broker 103

Topic-A
Partition 1

Topic Replication

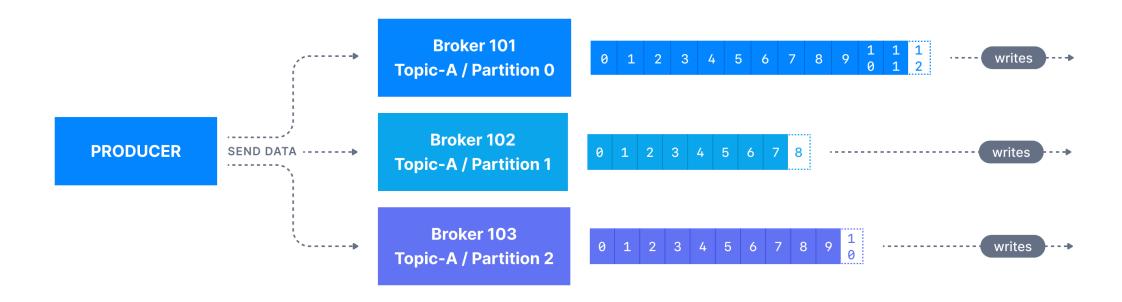
- In Produktionsumgebungen sollten Topics auf mehreren Brokern gespeichert werden
- Meistens wird ein Replication Factor von 3 verwendet
- Leader: Broker, der für die Partition zuständig ist
- In-Sync Replica: Broker, der die Partition repliziert und bei einem Ausfall übernehmen kann



Producer

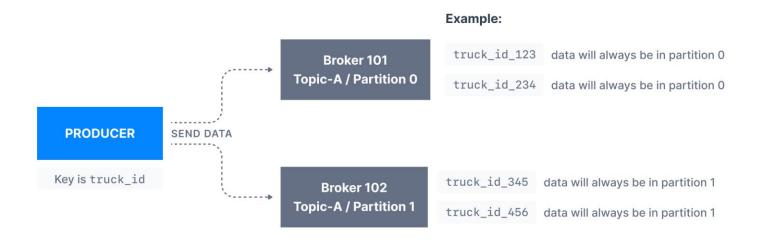
Producer: eine Anwendung, die Nachrichten in ein Kafka-Topic schreibt

- Producer verwenden i.d.R. eine Kafka-Library, um mit dem Cluster zu kommunizieren
- Kafka-Libraries existieren für fast alle Programmiersprachen (Java, Python, Go, ...)



Nachrichten-Keys

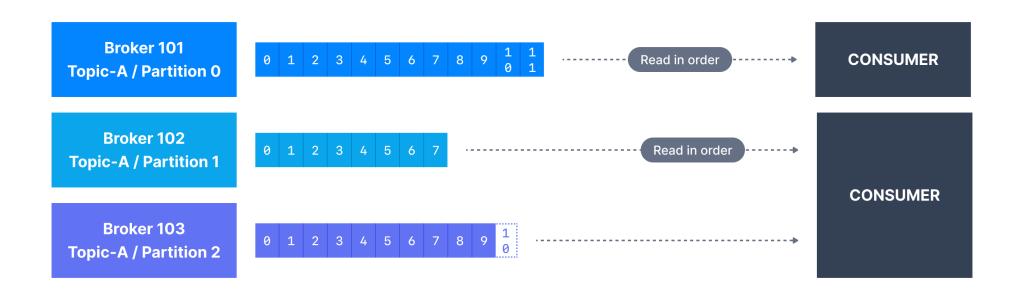
- Producer können eine Nachricht mit einem Key versehen
- Key=null → Nachrichten werden nach dem Round-Robin-Prinzip den Partitionen zugeordnet (Default-Partitioner)
- Key!=null → Nachrichten werden entsprechend des Key-Hashes den Partitionen zugeordnet
- Ein Key wird verwendet, wenn die Reihenfolge der Nachrichten relevant ist



Consumer

Consumer: eine Anwendung, die Nachrichten von einem Kafka-Topic liest

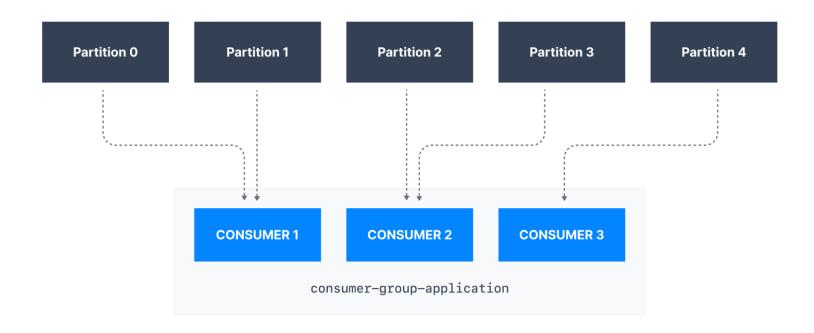
- Pull-Modell: Consumer müssen die Nachrichten selbst abrufen.
- Consumer verwenden wie die Producer i.d.R. eine Kafka-Libary, um mit dem Cluster zu kommunizieren



Consumer Groups

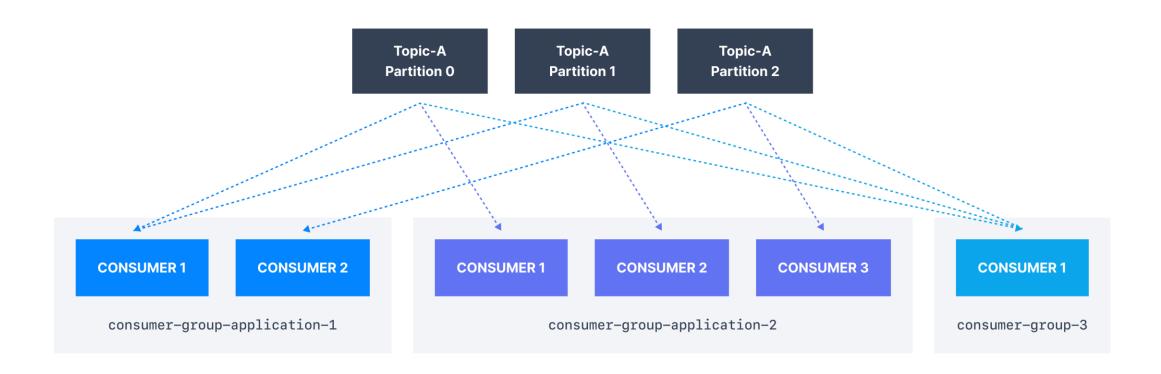
Consumer Group: eine Gruppe von Consumern, die den gleichen Job verrichten und sich die Arbeit aufteilen

- Jede Partition wird nur von einem Consumer innerhalb der Gruppe verarbeitet
- Ein Consumer innerhalb der Gruppe kann für mehrere Partitionen zuständig sein



Zusammenspiel von Consumer Groups

Mehrere Consumer Groups können das gleiche Topic verarbeiten



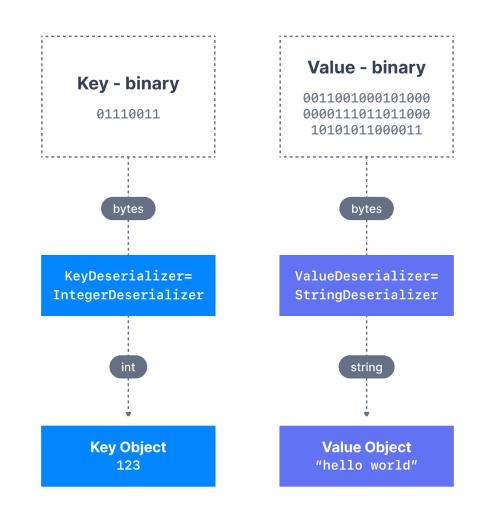
Consumer Offsets

- Consumer sollten das zuletzt von ihnen verarbeitete Offset committen.
- Stürzt der Consumer ab, kann ein anderer Consumer der gleichen Gruppe mit der Verarbeitung der Daten fortfahren
- Kafka bietet unterschiedliche Commit-Typen an:
 - At-Least-Once
 - At-Most-Once
 - Exactly-Once



Serializer und Deserializer

- Kafka-Broker verarbeiten die Nachrichten im Binärformat
- Producer und Consumer müssen für die Umwandlung von Nachrichten Serializer bzw. Deserializer verwenden
- Die Kafka-Libraries stellen für einige Datentypen bereits Serializer und Deserializer zur Verfügung (Integer, String, Float, Protobuf, ...)
- Für komplexe Datentypen können benutzerdefinierte Serializer und Deserializer implementiert werden



Hands-On

1. Aufsetzen eines Kafka-Clusters

URL zur Cloudplattform: https://upstash.com

2. Implementierung eines Wikimedia-Producers

URL zur Datenquelle: https://stream.wikimedia.org/v2/stream/recentchange

URL zur Producer-Vorlage: https://github.com/Daumel/data-engineering



Apache Spark

Batch-Verarbeitung

- Große Gruppen von Daten/Transaktionen werden in einem Durchgang verarbeitet.
- Jobs laufen ohne manuelle Eingriffe ab.
- Alle Daten sind vorab ausgewählt und werden über Kommandozeilenparameter und Skripte eingespeist.
- Wird verwendet, um mehrere Operationen auszuführen, schwere Datenlasten zu bewältigen, Berichterstattung und Offline-Daten-Workflow.
- **Beispiel:** Regelmäßige Berichte, die Entscheidungsfindung erfordern

Echtzeit-Verarbeitung

- Datenverarbeitung erfolgt sofort bei Dateneingabe oder Erhalt.
- Muss innerhalb strenger Zeitbeschränkungen ausgeführt werden.
- **Beispiel:** Betrugserkennung

MapReduce Limitations



Da es sich um ein batchorientiertes System handelt, dauert es Minuten, Jobs abhängig von der Datenmenge und der Anzahl der Knoten im Cluster auszuführen.

Ungeeignet für triviale Operationen

Bei Operationen wie Filter und Joins könnte es nötig sein, die Jobs umzuschreiben, was aufgrund des Schlüssel-Wert-Musters komplex wird.

Unpassend für große Datenmengen im Netzwerk

Es funktioniert nach dem Prinzip der Datenlokalität, kann jedoch nicht gut eine große Menge an Daten verarbeiten, die über das Netzwerk verschoben werden müssen.

MapReduce Limitations



OLTP erfordert eine große Anzahl kurzer Transaktionen, was aufgrund des Batch-orientierten Frameworks nicht umsetzbar ist.

Ungeeignet zur Verarbeitung von Graphen

Die Apache Giraph-Bibliothek verarbeitet Graphen und fügt zusätzliche Komplexität oben auf MapReduce hinzu.

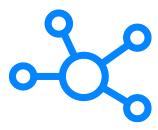
Ungeeignet für iterative Ausführung

Als zustandslose Ausführung passt MapReduce nicht zu Anwendungsfällen wie Kmeans, die iterative Ausführung benötigen.







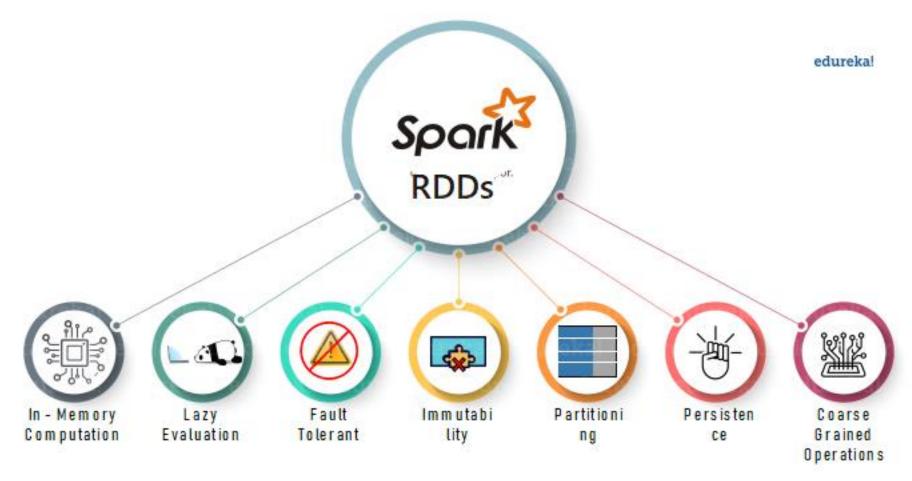


Distributed



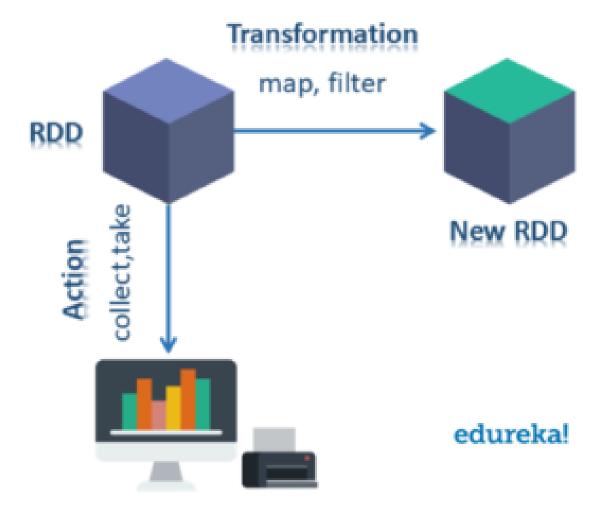
Dataset





https://www.edureka.co/blog/rdd-using-spark/





Dataframe and Dataset



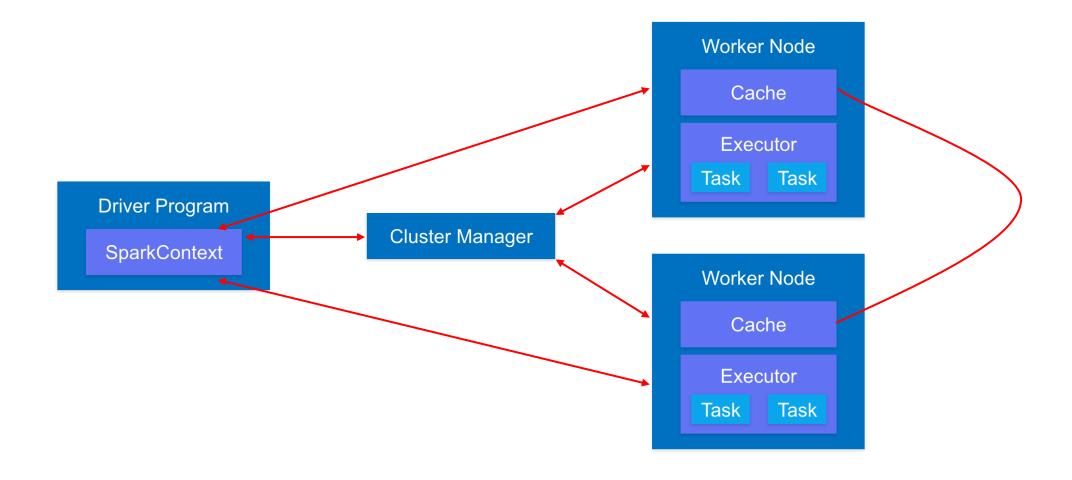
Abstraktion von RDD

Daten ähnlich zu RDBMS organisiert

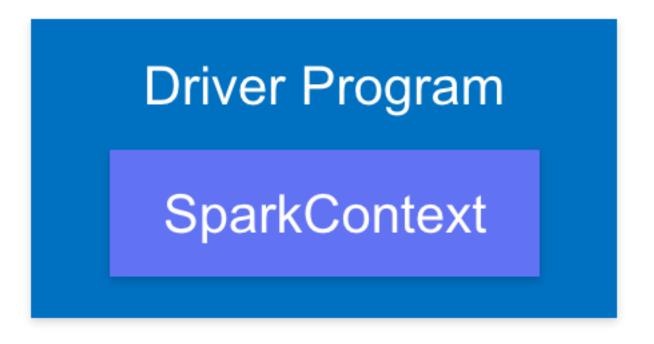
Einfacher zu verwenden, aber weniger Kontrolle

Kombiniert Vorteile von RDD und DF

Architecture



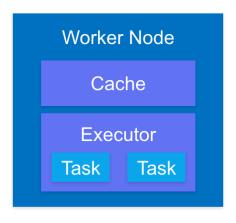
Architecture: Driver

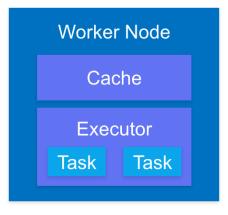


Architecture: Cluster Manager

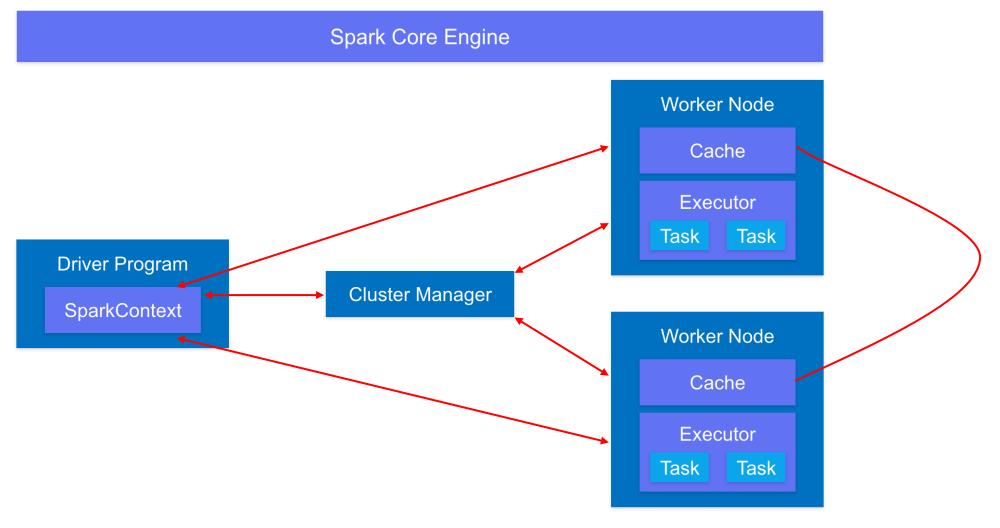
Cluster Manager

Architecture: Worker

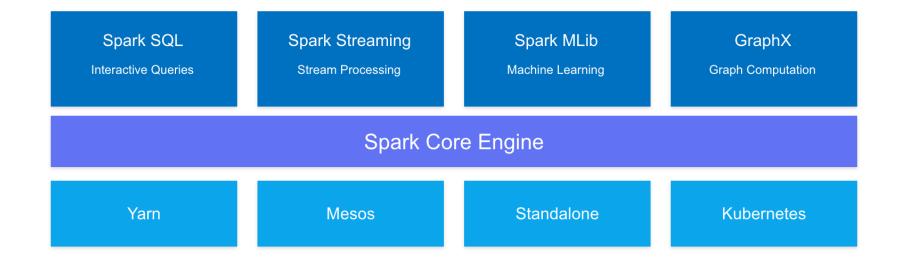




Architecture



Architecture



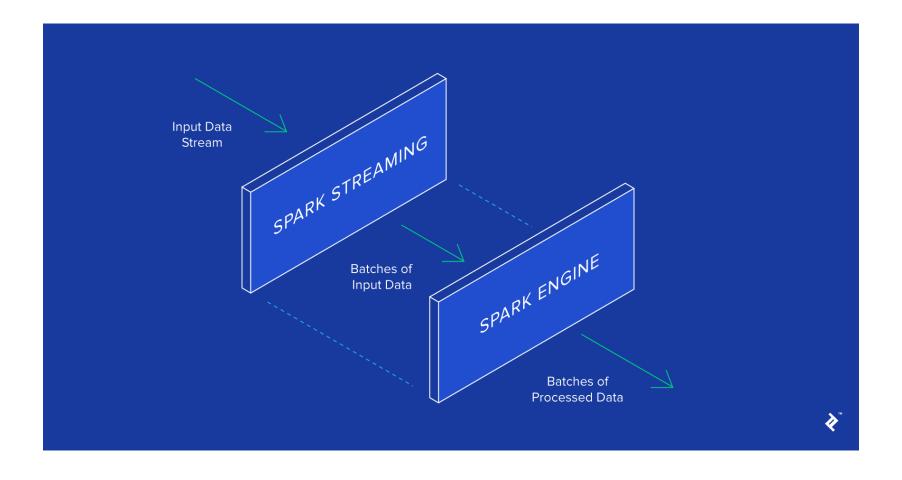
Spark SQL

Ermöglicht die Verwendung von SQL-Befehlen wie Select, Where, Group By, Join, etc.

```
// DataFrame API where()
df.select("country","city","zipcode","state")
   .where("state == 'AZ'")
   .show(5)
```

```
// sorting
df.select("country","city","zipcode","state")
  .where("state in ('PR','AZ','FL')")
  .orderBy("state")
  .show(10)
```

Spark Streaming



Code: RDD in Python

>>> textFile = spark.read.text("README.md")

Code: RDD Actions in Python

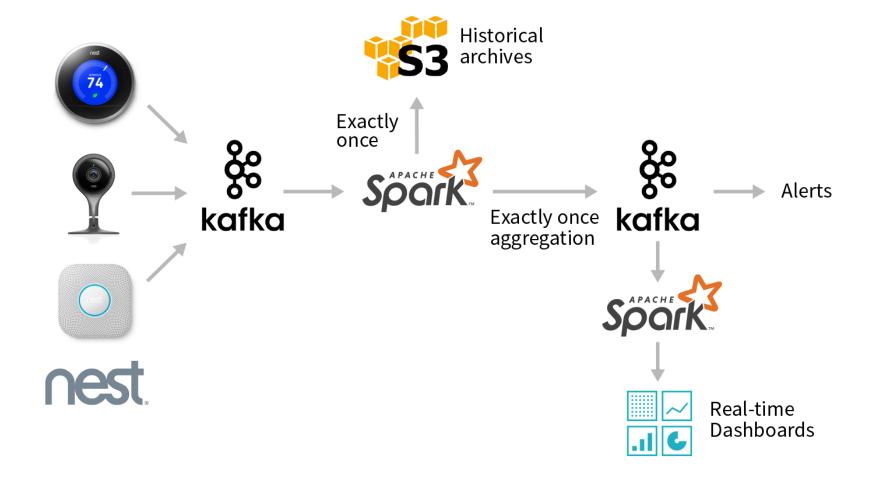
```
>>> textFile.count() # Number of rows in this DataFrame
126
>>> textFile.first() # First row in this DataFrame
Row(value=u'# Apache Spark')
```

Code: RDD Transformation in Python

```
>>> linesWithSpark = textFile.filter(textFile.value.contains("Spark"))
```

```
>>> from pyspark.sql import functions as sf
>>> textFile.select(sf.size(sf.split(textFile.value,
"\s+")).name("numWords")).agg(sf.max(sf.col("numWords"))).collect()
[Row(max(numWords)=15)]
```

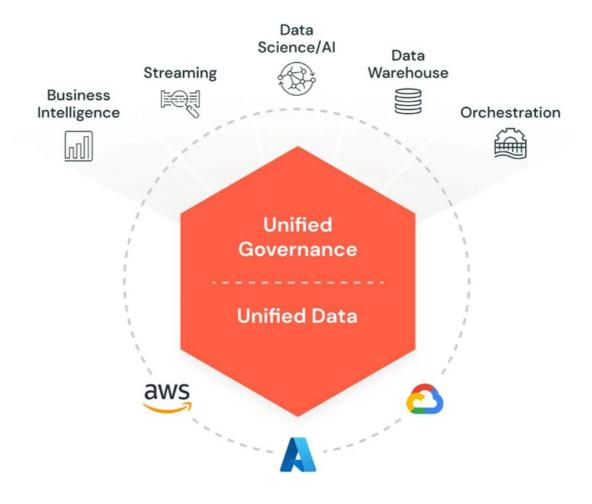
Integration von Apache Kafka und Apache Spark



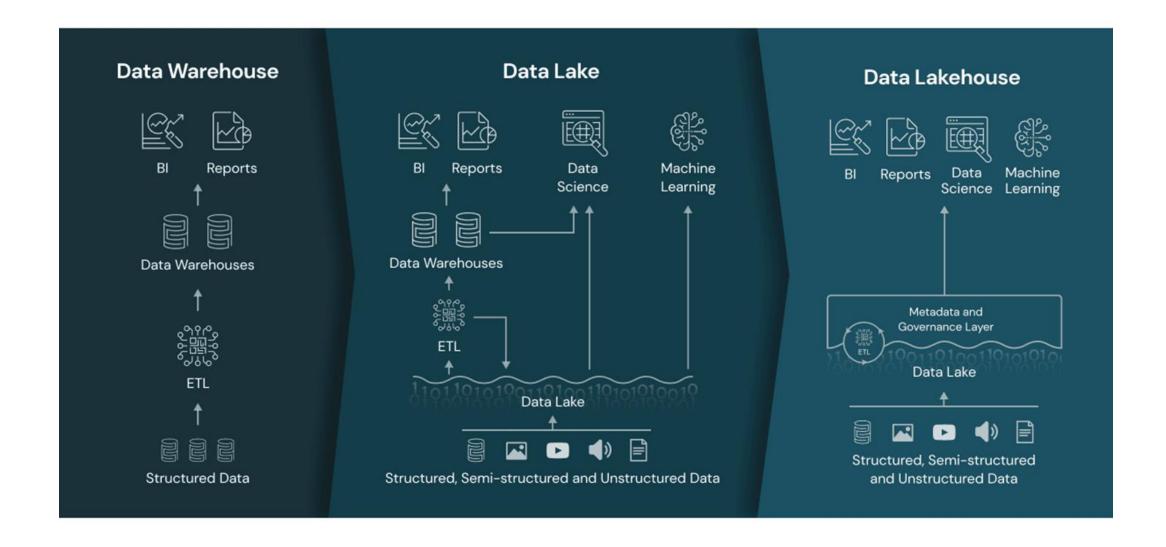


Databricks

Was ist Databricks?



Data Lakehouse Lösung



Argumente für Databricks



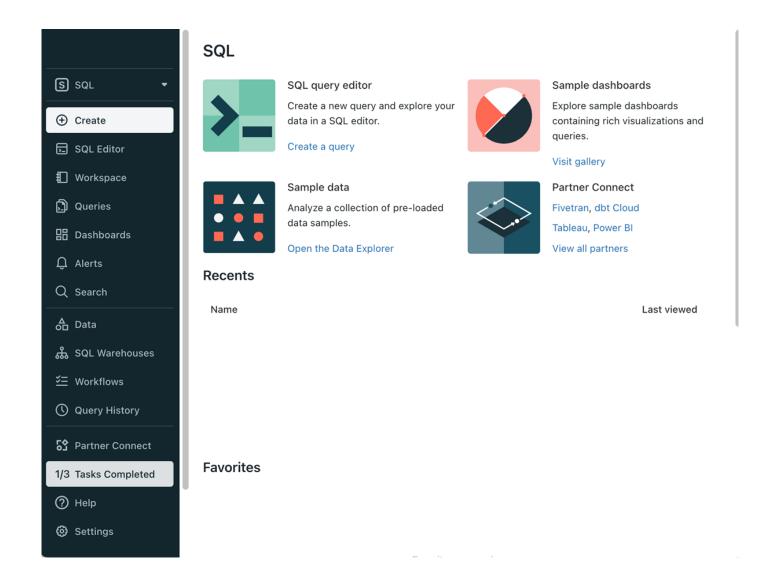


Spezialisiert auf Spark



Visuelle
Darstellung der
Daten

Demo



Hands-On

1. Registrieren bei Databricks

URL: https://www.databricks.com/try-databricks

Es ist wichtig, die Community-Edition bei der Registrierung auszuwählen!

2. Auswerten der Wikimedia-Daten

URL zum Databricks-Notebook: https://github.com/Daumel/data-engineering

